

# Pokročilé statistické metody

Alena Černíková

[alena.cernikova@ujep.cz](mailto:alena.cernikova@ujep.cz)

12. května 2025

# Realizace výuky

- **Výuku** realizují 2 vyučující
  - Alena Černíková
  - prof. Sergii Babichev
  
- **Zkoušku a zápočty** má na starosti jeden vyučující
  - Alena Černíková :(

# Podmínky zápočtu a zkoušky

- **Zápočet**

- dva až tři domácí úkoly – vyzkoušíte si příklady ze cvičení
- seminární práce – vypracování komplexního statistického úkolu, kde výstupem je souvislý text

- **Zkouška** – ústní u počítačů

- vylosujete si metodu, kterou předvedete na příkladu a vysvětlíte
- jedna otázka na mnohorozměrnou statistiku
- jedna otázka na regresní modely
- v případě nerozhodnosti známky doplňující otázka jedno ze tří témat:
  - fuzzy modely
  - Bayesovské sítě
  - věcná významnost

# Obsah kurzu

- Teorie testování hypotéz – AČ
- Věcná významnost a metaanalýza – AČ
- Mnohonásobná lineární regrese – SB
- Zobecněné lineární modely – SB
- Nelineární modely – SB
- Fuzzy logika a fuzzy modelování – SB
- Bayesovské metody – SB
- Mnohorozměrné statistické metody – AČ
- Dodatky k regresním modelům – AČ
- Praktické úkoly na výše zmížené – AČ

# Základy testování hypotéz

Testuje se platnost tvrzení

- Nový lék je lepší než stávající.
- Náhodná veličina má normální rozdělení.
- Průměrná výška lidí se za posledních 50 let zvýšila.
- Výnosy z jednotlivých druhů jabloní se liší.
- Krevní tlak závisí na hmotnosti.

Vždy se testují **populační charakteristiky**. Jejich výběrové ekvivalenty se používají jen pro sestrojení testových kritérií.

# Testované hypotézy

Při statistickém rozhodování testujeme proti sobě 2 hypotézy

- **Nulovou hypotézu** – značíme  $H_0$ 
  - obsahuje vždy jen jednu možnost
  - v případě testu nezávislosti sem patří **nezávislost**
  - v případě porovnání výběrů sem patří konkrétní velikost rozdílu (většinou nulová)  
**výběry jsou stejné**
- **Alternativní hypotézu** – značíme  $H_1$ 
  - obsahuje více možností (např. interval)
  - patří sem to, co chci prokázat
  - v případě testu nezávislosti sem patří **závislost**
  - v případě porovnání výběrů sem patří obecný popis rozdílu  
**výběry se liší**

# Výsledek testu

Na základě statistického testu uděláme jedno ze dvou rozhodnutí

- **Zamítneme nulovou hypotézu**
  - tím jsme prokázali platnost alternativy
- **Nezamítneme nulovou hypotézu**
  - tím jsme neprokázali nic
  - interpretace závisí na formulaci testovaných hypotéz
    - *neprokázala se platnost alternativy*
    - *nulová hypotéza může platit*

**Jiný závěr udělat nemohu!**

# Chyby testu

Při rozhodování můžeme udělat chybu

- **chyba prvního druhu** – zamítáme  $H_0$ , přestože platí  
 – značí se  $\alpha$ , a jmenuje se **hladina významnosti**  
 – závažnější z obou chyb
- **chyba druhého druhu** – nezamítáme  $H_0$ , přestože platí  $H_1$   
 – značí se  $\beta$  a hodnota  $1 - \beta$  se nazývá **síla testu**  
 – za dané hladiny významnosti chceme test co nejsilnější

	Nezamítáme $H_0$	Zamítáme $H_0$
Skutečně platí $H_0$	OK	Chyba I. druhu $\alpha$
Skutečně platí $H_1$	Chyba II. druhu $\beta$	OK síla testu

# Rozhodnutí

Výsledek testu získáme

- porovnáním **testové statistiky** ( $T$ ) a kritické hodnoty ( $c$ , jsou tabelovány)
- porovnáním  **$p$ -hodnoty** a hladiny významnosti ( $\alpha$ )

Platí, že

- absolutní hodnota testové statistiky  $|T| \geq c$  nebo  
 $p$ -hodnota  $\leq \alpha$  potom **ZAMÍTÁME  $H_0$**
- absolutní hodnota testové statistiky  $|T| < c$  nebo  
 $p$ -hodnota  $> \alpha$  potom **NEZAMÍTÁME  $H_0$**

# P-hodnota

## Co je to $p$ -hodnota

- aktuální dosažená hladina testu
- pravděpodobnost, že za platnosti  $H_0$  nastane výsledek, jaký nastal,  
nebo jakýkoliv jiný, který ještě více odpovídá alternativě
- definice  $p$ -hodnoty se týká testové statistiky

(Ne)zamítnut  $H_0$  nestačí, tento výsledek je třeba interpretovat  
vzhledem k položené otázce.

# Vybrané testy

## • **Testy rozdělení**

- nejčastěji testujeme normalitu
- př. Shapiro-Wilkův test,  $\chi^2$ -test dobré shody atd.

## • **Parametrické testy**

- testová statistika se počítá přímo z naměřených hodnot
- testuje se hodnota parametru, nejčastěji střední hodnoty
- předpokladem bývá konkrétní rozdělení, většinou normální
- př. dvouvýběrový t-test, ANOVA, Waldův test, Bartlettův test atd.

## • **Neparametrické testy**

- testová statistika je založena většinou na pořadích, ne přímo na naměřených hodnotách
- jedná se o robustní metody nevyžadující konkrétní rozdělení dat
- př. Wilcoxonův test, Spearmanův korelační koeficient atd.

## • **Simulační testy**

- nutnost využití počítačů
- na základě daného výběru se simulují další a počítá se p-hodnota
- př. permutační test, atd.

# Vybrané testy

- **Test o střední hodnotě jednoho výběru**
  - normální data – jednovýběrový t-test
  - nenormální data – znaménkový test, jednovýběrový Wilcoxonův test
- **Test o střední hodnotě rozdílu dvou závislých výběrů**
  - normální data – párový t-test
  - nenormální data – párový Wilcoxonův test
- **Test o stř. hodnotě rozdílu dvou nezávislých výběrů**
  - normální rozdělení, shodné rozptyly – dvouvýběrový t-test pro shodné rozptyly
  - normální rozdělení, různé rozptyly – dvouvýběrový Welchův test (t-test pro různé rozptyly)
  - nenormální rozdělení – dvouvýběrový Wilcoxonův test
- **Porovnání stř. hodnot více závislých výběrů**
  - normální data – ANOVA pro opakována měření
  - nenormální data – Friedmanův test
- **Porovnání stř. hodnot více nezávislých výběrů**
  - normální rozdělení, shodné rozptyly – klasická ANOVA pro shodné rozptyly
  - normální rozdělení, různé rozptyly – klasická ANOVA pro různé rozptyly
  - nenormální rozdělení – Kruskall-Wallisův test
- **Test o nezávislosti dvou číselných proměnných**
  - normální rozdělení – Pearsonův korelační koeficient
  - nenormální rozdělení – Spearmanův korelační koeficient
- **Test o vztahu dvou kategorických proměnných**
  - závislé proměnné, test symetrie – Mc Nemmarův test
  - test nezávislosti pro velká data – Chi-kvadrát test
  - test nezávislosti pro malá data – Fisherův test
  - test nezávislosti pro ordinální proměnné – Kendallův korelační koeficient

# Dvouvýběrový test

Porovnává střední hodnotu dvou **nezávislých** výběrů

## Testované hypozézy

- $H_0$  : střední hodnota  $X$  – střední hodnota  $Y = 0$
- $H_1$  : střední hodnota  $X$  – střední hodnota  $Y \neq 0, < 0, > 0$

Kontrolují se zde 2 předpoklady

- normalitu dat
- shodu rozptylů

A vybíráme jeden ze tří testů

- **Dvouvýběrový t-test** pro normální data a shodné rozptyly
- **Welchův dvouvýběrový test** pro normální data a různé rozptyly
- **Wilcoxonův dvouvýběrový test** pro data, která nemají normální rozdělení

# Test shody dvou rozptylů

Test shody rozptylů se využívá i u nenormálních dat.

Testované hypotézy

- $H_0$  : rozptyly se ve výběrech neliší
- $H_1$  : rozptyly se ve výběrech liší.

Testová statistika testu je

$$F = \frac{\text{Var}(X)}{\text{Var}(Y)} \sim F_{n_1 - 1, n_2 - 1}$$

a za platnosti  $H_0$  má  $F$ -rozdělení o  $n_1 - 1$  a  $n_2 - 1$  stupních volnosti.

# Dvouvýběrový t-test pro shodné rozptyly

Testová statistika tohoto testu má tvar

$$T = \frac{\bar{X} - \bar{Y} - \mu_0}{S} \sqrt{\frac{n_1 n_2}{n_1 + n_2}}$$

kde

$$S = \frac{1}{n_1 + n_2 - 2} \left( \sum_{i=1}^{n_1} (X_i - \bar{X})^2 + \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2 \right)$$

a  $n_1, n_2$  je rozsah výběru  $X$ , respektive  $Y$ . Za platnosti nulové hypotézy má tato statistika  $t$ -rozdělení o  $n_1 + n_2 - 2$  stupních volnosti.

# Welchův test

Testová statistika tohoto testu má tvar

$$T = \frac{\bar{X} - \bar{Y} - \mu_0}{\sqrt{\frac{\text{Var}(X)}{n_1} + \frac{\text{Var}(Y)}{n_2}}}$$

a za platnosti nulové hypotézy má  $t$ -rozdělení o  $\nu$  stupních volnosti, kde

$$\nu = \frac{(\text{Var}(X)/n_1 + \text{Var}(Y)/n_2)^2}{\frac{(\text{Var}(X)/n_1)^2}{n_1-1} + \frac{(\text{Var}(Y)/n_2)^2}{n_2-1}}.$$

kritické hodnoty je možno odvodit, přestože  $\nu$  není celé číslo.

# Dvouvýběrový t-test

**Příklad.** Ve výběru mám 222 jedenáctiletých dětí, z toho 159 hochů a 63 dívek. Průměrná hmotnost hochů vyšla 38.1 kg a u dívek 39.1. Směrodatná odchylka pro hochy vyšla 6.7 kg a pro dívky 7.1. Je hmotnost jedenáctiletých dětí v průměru stejná pro hochy jako pro dívky? Předpokládejme přibližně normální rozdělení dat.

Test shody rozptylů

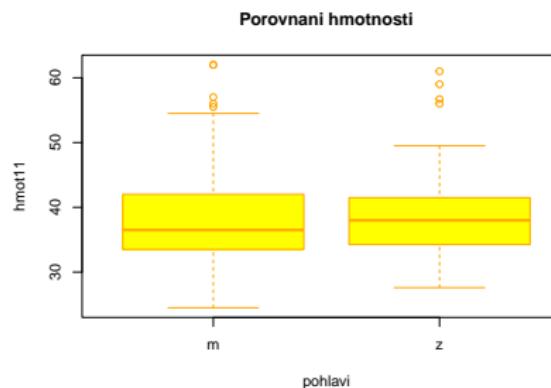
- testová statistika  $F = \frac{\text{Var}(X)}{\text{Var}(Y)} = \frac{45.1}{50.6} = 0.89$
- p-hodnota  $= 0.56 > \alpha = 0.05$
- **nulovou hypotézu nezamítáme**
- rozptyly ve skupinách jsou přibližně stejné a můžeme použít dvouvýběrový t-test pro shodné rozptyly

# Dvouvýběrový t-test

Testujeme

- $H_0$  : hmotnost hochů a hmotnost dívek se neliší  
hmotnost hochů – hmotnost dívek = 0
- $H_1$  : hmotnost hochů a dívek se liší  
hmotnost hochů – hmotnost dívek  $\neq 0$

Grafické porovnání



# Dvouvýběrový t-test

- testová statistika

$$T = \frac{\bar{X} - \bar{Y} - \mu_0}{S} \sqrt{\frac{n_1 n_2}{n_1 + n_2}} = \frac{38.1 - 39.1}{6.83} \sqrt{\frac{159 \times 63}{159 + 63}} = -1.001$$

- porovnáváme s kvantilem t-rozdělení  
 $t_{220}(1 - 0.025) = 1.97$  (kvantil pro oboustrannou alternativu)
- testová statistika je v absolutní hodnotě menší než tento kvantil, tak **nulovou hypotézu nezamítám.**
- p-hodnota = 0.3151 >  $\alpha = 0.05$
- **Závěr:** Na hladině významnosti 5% jsem neprokázala, že by se hmotnost jedenáctiletých hochů a dívek lišila.

# Wilcoxonův dvouvýběrový test

Používá se pro porovnání dvou nezávislých výběrů, které nesplňují předpoklad normality.

Test je založen na pořadích hodnot sdruženého výběru.

## Postup

- oba výběry se spojí do jednoho sdruženého
- sdružený výběr se uspořádá podle velikosti a každé pozorování dostane své pořadí
- pro oba výběry se vypočte součet pořadí a následně i průměrné pořadí
- pokud jsou si průměrná pořadí podobná, výběry se mezi sebou významně neliší

## Wilcoxonův dvouvýběrový test

Technický výpočet: označme  $T_1, T_2$  součet pořadí v prvním, respektive druhém výběru. Dále vypočteme

$$U_1 = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - T_1, \quad U_2 = n_1 n_2 + \frac{n_2(n_2 + 1)}{2} - T_2,$$

kde  $n_1, n_2$  jsou rozsahy jednotlivých výběrů. Přesný test porovnává hodnotu  $\min(U_1, U_2)$  s kritickou hodnotou.

Asymptoticky platí, že

$$U_0 = \frac{U_1 - \frac{1}{2} n_1 n_2}{\sqrt{\frac{n_1 n_2}{12} (n_1 + n_2 + 1)}}$$

má za platnosti  $H_0$   $N(0, 1)$  rozdělení.

# Wilcoxonův dvouvýběrový test

**Příklad.** Chceme porovnat výsledky testů studentů v Ústí nad Labem a v Liberci. Studenti v Ústí dostali bodová ohodnocení 45, 79, 81, 56, 53, 77. Studenti v Liberci získali ohodnocení 76, 62, 84, 80, 41, 79, 66. Testujeme

- $H_0$  : Studenti v Ústí a v Liberci jsou stejní
- $H_1$  : Studenti v Ústí a v Liberci se liší.
- V prvním kroku srovnám všechny hodnoty do řady  
41, 45, 53, 56, 62, 66, 76, 77, 79, 79, 80, 81, 84
- následně jím přiřadím pořadí  
1, 2, 3, 4, 5, 6, 7, 8, 9.5, 9.5, 11, 12, 13
- pak vypočtu  
 $T_1 = 38.5$ ,  $T_2 = 52.5$ ,  $U_1 = 24.5$ ,  $U_2 = 17.5$ ,  $U_0 = 0.5$ ,  $p = 0.6678$

$P$ -hodnota  $> \alpha$  a tedy nezamítám nulovou hypotézu, neprokázal se rozdíl mezi studenty v Ústí a v Liberci.

# Chí-kvadrát test nezávislosti

Vztah dvou kategorických proměnných popisujeme **tabulkou absolutních četností**. Označme

- $X_1, \dots, X_k$  hodnoty jedné kategorické proměnné
- $Y_1, \dots, Y_l$  hodnoty druhé kategorické proměnné
- $n_{i,j}$  četnost současného výskytu znaků  $X_i, Y_j$
- $n_{i \cdot}$  marginální četnost znaku  $X_i$
- $n_{\cdot j}$  marginální četnost znaku  $Y_j$
- $n$  celkový počet pozorování

# $\chi^2$ -test nezávislosti

Kontingenční tabulka absolutních četností má tvar

	$Y_1$	$\dots$	$Y_l$	
$X_1$	$n_{1,1}$	$\dots$	$n_{1,l}$	$n_{1\cdot}$
$\vdots$		$\ddots$		$\vdots$
$X_k$	$n_{k,1}$	$\dots$	$n_{k,l}$	$n_{k\cdot}$
	$n_{\cdot 1}$	$\dots$	$n_{\cdot l}$	$n$

# $\chi^2$ -test nezávislosti

## Testované hypotézy

- $H_0$  : proměnné na sobě nezávisí
- $H_1$  : proměnné na sobě závisí

Test je založen na porovnání

- pozorovaných četností  $n_{ij}$
  - očekávaných četností  $n_{i\cdot} \cdot n_{\cdot j} / n$
- vychází z definice nezávislosti  $P(A \cap B) = P(A)P(B)$

## Testová statistika

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{(pozorovane_{i,j} - ocekavane_{i,j})^2}{ocekavane_{i,j}} = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{i,j} - n_{i\cdot} \cdot n_{\cdot j} / n)^2}{n_{i\cdot} \cdot n_{\cdot j} / n}$$

za platnosti  $H_0$  má  $\chi^2$ -rozdělení o  $(k-1)(l-1)$  stupních volnosti.

# Fisherův exaktní test

## Test nezávislosti pro malá data

- když není splněn předpoklad  $\chi^2$ -testu, tj. některá očekávaná četnost je menší než 5
- počítá přímo p-hodnotu ke konkrétní tabulce
- známý též jako **Fisherův faktoriálový test**

Pro čtyřpolní tabulku

	$Y_1$	$Y_2$	
$X_1$	$n_{11}$	$n_{12}$	$n_{1\cdot}$
$X_2$	$n_{21}$	$n_{22}$	$n_{2\cdot}$
	$n_{\cdot 1}$	$n_{\cdot 2}$	$n$

se p-hodnota vypočítá následujícím způsobem

$$p = \frac{n_{\cdot 1}! n_{\cdot 2}! n_{1\cdot}! n_{2\cdot}!}{n! n_{11}! n_{12}! n_{21}! n_{22}!}$$

Pro větší tabulky je test složitější.

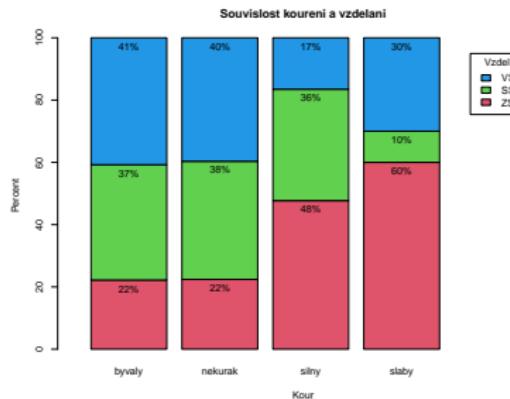
# $\chi^2$ -test nezávislosti

**Příklad.** U 204 mužů s jedním rizikovým faktorem ischemické choroby srdeční bylo zjištěno vzdělání a kategorie kouření. Výsledky jsou shrnuty v následující tabulce absolutních četností. Souvisí spolu tyto dvě veličiny?

	ZŠ	SŠ	VŠ
bývalý kuřák	6	10	11
nekuřák	13	22	23
slabý kuřák	52	39	18
silný kuřák	6	1	3

# $\chi^2$ -test nezávislosti

Vztah dvou kategorických proměnných se zobrazuje pomocí sloupcového grafu



Můžeme zobrazovat pomocí řádkových nebo sloupcových procent.

# $\chi^2$ -test nezávislosti

## Testované hypotézy

- $H_0$  : kouření se vzděláním nesouvisí
- $H_1$  : kouření se vzděláním souvisí

## Výsledky testu

- testová statistika  $\chi^2$  testu  $21.286 > 12.59$ , kvantil  $\chi^2$ -rozdělení s 6 stupni volnosti
- p-hodnota  $0.00163 < \alpha = 0.05$
- p-hodnotu Fisherova exaktního testu  $0.00084 < \alpha = 0.05$
- některé očekávané četnosti jsou menší než 5 (není splněn předpoklad  $\chi^2$  testu)
- na základě Fisherova testu **zamítáme nulovou hypotézu**

**Závěr:** Prokázali jsme, že kouření se vzděláním souvisí.

# Poměr šancí

Uvažujme dvouhodnotovou veličinu ve dvou populacích.

- např. sledujeme výskyt chřipky ve městě a na venkově

	Chřipku má	Chřipku nemá	
Město	$n_{11}$	$n_{12}$	$n_{1\cdot}$
Venkov	$n_{21}$	$n_{22}$	$n_{2\cdot}$
	$n_{\cdot 1}$	$n_{\cdot 2}$	$n$

Rozdíl mezi populacemi je možné popsat **poměrem šancí**.

- šance** "mít chřipku proti nemít chřipku"

$$Odds = \frac{P(\text{má chřipku})}{P(\text{nemá chřipku})}$$

- poměr šancí je podíl šancí v obou populacích.

# Poměr šancí

## Definice poměru šancí

$$OR = \frac{n_{11}n_{22}}{n_{12}n_{21}}$$

Interpretace tohoto poměru říká, kolikrát je větší šance na chřipku ve městě než na venkově.

## Testované hypotézy

- $H_0 : OR = 1$ , šance jsou stejné
- $H_1 : OR \neq 1$ , šance se v populacích liší

Testová statistika je rovna

$$Z = \frac{\ln(OR)}{\sqrt{\frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}}}}$$

a za platnosti nulové hypotézy má  $N(0, 1)$  rozdělení.

# Poměr šancí

**Příklad.** Uvažujme následující čtyřpolní tabulku

	<i>Chřipku má</i>	<i>Chřipku nemá</i>	
<i>Město</i>	58	17	75
<i>Venkov</i>	32	30	62
	90	47	137

- šance mít chřipku ve městě vychází  $58/17 = 3.41$
- šance mít chřipku na venkově vychází  $32/30 = 1.07$
- poměr šancí ve městě vs. na venkově vychází  $3.41/1.07 = 3.2$   
*Ve městě je více než třikrát větší šance mít chřipku než na venkově.*
- testová statistika  $3.27 > 1.96$  kritická hodnota
- $p$ -hodnota  $0.001 < \alpha = 0.05$
- *zamítáme nulovou hypotézu*

**Závěr:** Ve městě je významně větší šance dostat chřipku než na venkově.

# Statistický test

Výše uvedené testy měří statistickou významnost. Je ale tato významnost i skutečně zajímavá?

- p-hodnota statistického testu závisí na počtu pozorování
- málo pozorování dává "velkou" p-hodnotu
- hodně pozorování dává "malou" p-hodnotu
- statistické testy dobře fungují pro počet pozorování kolem 100 hodnot

# Odhad počtu pozorování

Existuje vztah mezi počtem pozorování, hladinou významnosti a sílou testu.

Zvolme

- hladinu významnosti  $\alpha = 0.05$
- sílu testu  $1 - \beta = 0.9$
- typ testu: dvouvýběrový t-test
- minimální zajímavý rozdíl mezi skupinami  $|\mu_1 - \mu_2| = 2$
- očekávanou variabilitu  $\sigma = 5$

## Optimální počet pozorování v každé skupině

$$n_1 = 2 \left( \frac{z(1 - \alpha) + z(1 - \beta)}{\frac{|\mu_1 - \mu_2|}{\sigma}} \right)^2 = 2 \left( \frac{1.96 + 1.28}{2/5} \right)^2 = 131.4$$

# Odhad počtu pozorování

- optimální je stejný počet pozorování v obou skupinách
- pokud očekáváte, že budete používat Wilcoxonův dvouvýběrový test, přidejte navíc 15% pozorování
- počet pozorování je možné odhadnout i pro požadovanou délku intervalu spolehlivosti

# Tabulka analýzy rozptylu

- používá se pro porovnání variability **vysvětlené** a variability **nevysvětlené**
- nejčastěji v ANOVě (porovnání střední hodnoty v několika nezávislých výběrech)
- označme

$$SST = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{..})^2$$

$$SSA = \sum_{i=1}^k n_i (\bar{X}_{i.} - \bar{X}_{..})^2$$

$$SSe = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i.})^2$$

# Tabulka analýzy rozptylu

	Součty čtverců	Stupně volnosti	Průměrné čtverce	Testová statistika	p-hodnota
Faktor A	$SSA$	$dfA = k - 1$	$MSA = \frac{SSA}{dfA}$	$F = MSA / MSe$	$p$
Chyba e	$SSe$	$dfe = n - k$	$MSe = \frac{SSe}{dfe}$		
Celkem	$SST$	$dft = n - 1$			

Za platnosti nulové hypotézy má testová statistika  $F$ -rozdělení o  $k - 1$  a  $n - k$  stupních volnosti.

## Věcná významnost

Pro posouzení věcné významnosti jsou vytvořeny ukazatele, které pomohou určit, zda zjištěná statistická významnost je skutečně zajímavá. Tyto ukazatele se převážně používají u velkých vzorků dat.

Velké vzorky můžeme získat např. v rámci metaanalýzy, tj. kombinace několika výzkumů na stejné téma.

# Porovnání dvou výběrů

- **Cohenovo  $d$**

$$d = \frac{\bar{X} - \bar{Y}}{\sqrt{S^2}}, \quad S^2 = \frac{n_1 S_1^2 + n_2 S_2^2}{n_1 + n_2}$$

do 0.5 malý efekt, 0.5-0.8 střední efekt, nad 0.8 velký efekt

- **Hedgesovo  $g$**

$$g = \frac{\bar{X} - \bar{Y}}{\sqrt{MSe}},$$

$MSe$  jsou residuální "průměrné čtverce" z tabulky analýzy rozptylu  
do 0.5 malý efekt, 0.5-0.8 střední efekt, nad 0.8 velký efekt

- **Glassovo  $\delta$**

$$\delta = \frac{\bar{X} - \bar{Y}}{\sqrt{S_k^2}}$$

$S_k^2$  je rozptyl kontrolní skupiny

do 0.5 malý efekt, 0.5-0.8 střední efekt, nad 0.8 velký efekt

# Porovnání více výběrů

- **Fisherovo  $\eta^2$**

$$\eta^2 = \frac{SSA}{SST}$$

kde  $SSA$  a  $SST$  jsou součty čtverců z tabulky analýzy rozptylu  
procento vysvětlené variability

- **Haysova  $\omega^2$**

$$\omega^2 = \frac{SSA - (k - 1)MSe}{SST + MSe}$$

kde  $SSA$ ,  $SST$  a  $MSe$  jsou součty čtverců/průměrné čtverce z tabulky analýzy rozptylu  
procento vysvětlené variability

# Vztah dvou kategorických proměnných

- Cramerovo  $\phi$

$$\phi = \sqrt{\frac{\chi^2}{n}} = \sqrt{\sum_{i=1}^k \frac{(p_i - p_{0i})^2}{p_{0i}}}$$

kde  $\chi^2$  je testová statistika  $\chi^2$ -testu

do 0.29 malý efekt, 0.3-0.49 střední efekt, nad 0.5 velký efekt

- Cramerovo  $V$

$$V = \sqrt{\frac{\chi^2}{n(k-1)}}$$

hodnota od 0 do 1 chovající se přibližně jako korelační koeficient

# Vztah dvou číselných proměnných

- **korelační koeficient  $r$**

$$\text{Cor}(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

do 0.3 malý efekt, 0.3-0.7 střední efekt, nad 0.7 velký efekt

- **koeficient determinace  $R^2$**

$$R^2 = \text{Cor}^2(X, Y) = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y}_i)^2}$$

do 0.01 malý efekt, 0.01-0.25 střední efekt, nad 0.25 velký efekt

procento variability vysvětlené modelem

# Základy mnohorozměrné statistiky

Nepracuje se s jednou proměnnou  $X$ , ale s vektorem proměnných  $\mathbf{X} = (X_1, X_2, \dots, X_k)^T$ .

## Příklady

- Měříme několik fyzických parametrů jedince: výška, váha, krevní tlak, vitální kapacitu plic, atd.
- Každý žák na vysvědčení dostane známku z několika předmětů: čeština, matematika, zeměpis, přírodopis, atd.
- Zkoumáme chemické složení roztoku a máme zastoupení jednotlivých prvků: železo, sodík, draslík, atd.
- Klient banky vyplní dotazník, tj. odpoví na skupinu otázek

# Základní charakteristiky

- střední hodnota

$$\mu = (\mu_1, \dots, \mu_k)^T$$

- varianční matice

$$\Sigma = (\sigma_{ij}) = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1k} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2k} \\ \vdots & \ddots & \ddots & \vdots \\ \sigma_{k1} & \sigma_{k2} & \dots & \sigma_k^2 \end{pmatrix}$$

kde  $\sigma_{ij} = \sigma_{ji}$  je kovariance  $i$ -té a  $j$ -té složky

- odhad střední hodnoty je vektor průměrů

$$\bar{\mathbf{X}} = (\bar{X}_1, \dots, \bar{X}_k)^T$$

- odhad varianční matice je matice výběrových kovariancí a rozptylů  $\mathbf{S} = (\mathbf{s}_{ij})$ , kde  $s_{ij} = \text{cov}(X_i, X_j)$  pro  $i \neq j$  a  $s_{ii} = \text{Var}(X_i)$

# Měření vzdálenosti

- **Eukleidovská vzdálenost:**

$$d(\mathbf{X}, \mathbf{Y}) = \|\mathbf{X}_i - \mathbf{Y}_i\| = \sqrt{(\mathbf{X} - \mathbf{Y})^T (\mathbf{X} - \mathbf{Y})} = \sqrt{\sum_{i=1}^k (X_i - Y_i)^2}$$

**nevýhoda:** všechny složky přispívají do vzdálenosti stejnou měrou a není zohledněn jejich vzájemný vztah

- **Mahalanobisova vzdálenost:**

$$d(\mathbf{X}, \mathbf{Y}) = \sqrt{(\mathbf{X} - \mathbf{Y})^T \mathbf{S}^{-1} (\mathbf{X} - \mathbf{Y})}$$

pro nezávislé vektory dostáváme

$$d(\mathbf{X}, \mathbf{Y}) = \sqrt{\sum_{i=1}^k \frac{(X_i - Y_i)^2}{s_{ii}^2}}$$

kde  $\mathbf{S} = \text{cov}(\mathbf{X}, \mathbf{Y})$  je kovarianční matice vektorů  $\mathbf{X}$  a  $\mathbf{Y}$

# Zobecnění jednorozměrných metod

- Dvouvýběrový test ⇒ **Hotellingův test**
- Analýza rozptylu (ANOVA) ⇒ **MANOVA**
- Korelační koeficient ⇒ **Kanonické korelace**
- Lineární regrese ⇒ **Mnohorozměrná lineární regrese**,  
kde závisle proměnná má více složek.

# Hotellingův test

- zobecnění dvouvýběrového testu
- porovnávám střední hodnotu ve dvou nezávislých výběrech
- testované hypotézy
  - $H_0$  : vektory středních hodnot se rovnají
  - $H_1$  : vektory středních hodnot se liší
- testová statistika

$$T^2 = \frac{n_1 n_2}{n_1 + n_2} (\bar{\mathbf{X}} - \bar{\mathbf{Y}})^T \mathbf{S}^{-1} (\bar{\mathbf{X}} - \bar{\mathbf{Y}})$$

$$\mathbf{S} = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}$$

- za platnosti  $H_0$  má Hotellingovo  $T^2$ -rozdělení s  $k$  a  $n_1 + n_2 - 2$  stupni volnosti
- odpovídá  $F$ -rozdělení  $T^2 \sim \frac{(n_1+n_2-2)k}{n_1+n_2-k-1} F_{k, n_1+n_2-k-1}$

# MANOVA

- zobecnění analýzy rozptylu
- porovnávám střední hodnotu ve více nezávislých výběrech
- testované hypotézy
  - $H_0$  : vektory středních hodnot se rovnají
  - $H_1$  : vektory středních hodnot se liší
- porovnává se variabilita vysvětlená a nevysvětlená

$$\mathbf{W} = \sum_{i=1}^p \sum_{j=1}^{n_i} (\mathbf{Y}_{ij} - \bar{\mathbf{Y}}_i)^T (\mathbf{Y}_{ij} - \bar{\mathbf{Y}}_i)$$

$$\mathbf{B} = \sum_{i=1}^p n_i (\bar{\mathbf{Y}}_i - \bar{\mathbf{Y}})^T (\bar{\mathbf{Y}}_i - \bar{\mathbf{Y}})$$

- kde  $p$  značí počet výběrů a  $\bar{\mathbf{Y}}_i$  průměr  $i$ -tého výběru.

# MANOVA

Testové statistiky pro MANOVu.

- **Wilkovo lambda**

$$\Lambda_W = \det \left( \frac{\mathbf{W}}{\mathbf{W} + \mathbf{B}} \right)$$

- **Pillayova stopa**

$$\Lambda_P = \text{tr} \left( \frac{\mathbf{B}}{\mathbf{W} + \mathbf{B}} \right)$$

- **Hotellingovo lambda**

$$\Lambda_H = \text{tr} \left( \frac{\mathbf{B}}{\mathbf{W}} \right)$$

při porovnání dvou výběrů se všechny zjednoduší na Hotellingův dvouvýběrový test.

# Metoda hlavních komponent (PCA)

## Principal component analysis

- zjednodušení dat
- využívá se při práci s velkým množstvím proměnných
- proměnné se transformují tak, aby se většina informace soustředila do malého počtu nových veličin
- zjednodušení je podmíněné tím, že vstupní proměnné nejsou nezávislé
- hlavní využití při grafickém zobrazení výstupů

# Transformace proměnných

Nově vzniklé proměnné jsou lineární kombinací původních

$$\mathbf{Y} = \mathbf{X}^T \mathbf{P}$$

kde

- $\mathbf{X}$  je centrovavá matice vstupních hodnot (centrování = odečet průměru)
- $\mathbf{Y}$  je matice cílových/ výstupních proměnných
- $\mathbf{P}$  je matice transformačních vektorů

Matici  $\mathbf{P}$  získáme pomocí rozkladu **korelační matice** vstupních dat  $\mathbf{C}$

$$\mathbf{C} = \mathbf{P} \Lambda \mathbf{P}^T$$

kde

- $\Lambda$  je matice vlastních čísel matice  $\mathbf{C}$
- $\mathbf{P}$  je matice vlastních vektorů matice  $\mathbf{C}$

# Vsuvka

**Vlastní čísla a vlastní vektory matice** Bud'  $\mathbf{A}$  čtvercová matice řádu  $n$

- vlastní, neboli charakteristické číslo matice  $\mathbf{A}$  je takové, pro které platí

$$\det(\mathbf{A} - \lambda \mathbf{I}) = 0$$

- matice řádu  $n$  má  $n$  vlastních čísel, některé mohou být vícenásobné
- vlastní vektor  $\mathbf{v}$  matice  $\mathbf{A}$  příslušný k vlastnímu číslo  $\lambda$  splňuje

$$(\mathbf{A} - \lambda \mathbf{I})\mathbf{v} = 0$$

# Vlastnosti hlavních komponent

Výsledná matice hlavních komponent  $\mathbf{Y}$  má následující vlastnosti

- její vektory jsou vzájemně nezávislé (kolmé)
- součet koeficientů lineární transformace u každé komponenty je 1
- řadí se podle velikosti variability: od vektoru s největší variabilitou k vektoru s nejnižší variabilitou
- obsahuje veškerou informaci, kterou obsahovala původní data

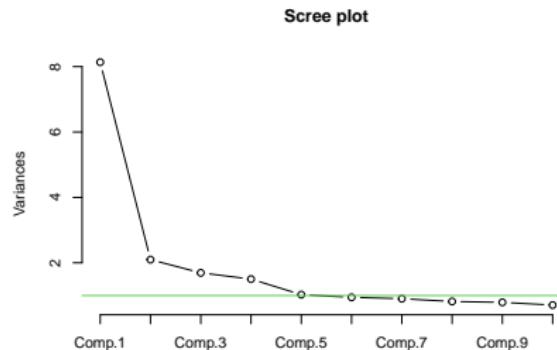
# Intuitivní představa PCA

Celý **postup** si můžeme představit následovně

- mějme mnohorozměrná data v prostoru
- daty proložíme vektor ve směru s největší variabilitou
- tak získáme první hlavní komponentu
- hledáme vektor, který by byl k prvnímu kolmý a opět byl ve směru s největší variabilitou
- získáme druhou hlavní komponentu
- hledáme vektor, který by byl kolmý k prvním dvěma a byl ve směru s největší variabilitou
- získáme třetí hlavní komponentu
- poslední dva kroky opakujeme, dokud máme body ve volném prostoru

# Optimální počet hlavních komponent

- **počet** hlavních komponent dostačující k reprezentaci informace obsažené ve vstupních datech odpovídá počtu vlastních čísel korelační matice větších než 1
- grafické znázornění tohoto počtu: *Scree plot*



# Faktorová analýza

Nevýhodou hlavních komponent je, že nemají přirozenou interpretaci. Pokud chceme získat menší počet proměnných, které jsou interpretovatelné, používá se **faktorová analýza**.

**Hlavní myšlenka** faktorové analýzy pochází z psychologie:

- na každého působí *k* neměřitelných faktorů
- podle toho, jak na nás působí, my reagujeme
- podle reakcí na  $p$  podnětů se snažíme identifikovat původní faktory

# Faktorová analýza

**Příklad.** Děti nosí ze školy vysvědčení. Podle známek, pak lze identifikovat dvě skupiny studentů, jedna z nich má dobré známky v předmětech matematika, fyzika, přírodopis, zeměpis, chemie, druhá má dobré známky v předmětech čeština, angličtina, dějepis, občanská výchova. Faktory, které na ně působí jsou pak přírodní vědy a humanitní obory.

# Faktorová analýza

Vycházíme z rovnice obdobné jako u analýzy hlavních komponent

$$\mathbf{X} = \mathbf{LF} + \boldsymbol{\varepsilon}$$

kde

- $\mathbf{X}$  je centrovaná matice naměřených dat
- $\mathbf{L}$  jsou tzv. *loadings*
- $\mathbf{F}$  jsou hledané faktory
- $\boldsymbol{\varepsilon}$  jsou náhodné chyby

# Předpoklady faktorové analýzy

Aby bylo možné faktory odhadnout, musí platit

- $\mathbf{F}$  a  $\varepsilon$  jsou nezávislé
- $E(\mathbf{F}) = \mathbf{0}$  a  $Cov(\mathbf{F}) = \mathbf{I}$ , kde  $\mathbf{I}$  je jednotková matice,  
tj. faktory mají nulovou střední hodnotu, jednotkový rozptyl  
a jsou nezávislé
- $E(\varepsilon) = \mathbf{0}$  a  $Cov(\varepsilon) = \sigma^2 \mathbf{I}$ ,  
tj. náhodné chyby jsou nezávislé, stejně rozdělené s  
nulovou střední hodnotou a konstantním rozptylem  $\sigma^2$
- $Cov(\mathbf{X}) = \mathbf{L}\mathbf{L}' + \sigma^2 \mathbf{I}$ , tedy
  - $Var(X_i) = \ell_{i1}^2 + \ell_{i2}^2 + \dots + \ell_{im}^2 + \sigma^2$
  - $Cov(X_i, X_j) = \ell_{i1}\ell_{j1} + \ell_{i2}\ell_{j2} + \dots + \ell_{im}\ell_{jm}$
- $Cov(\mathbf{X}, \mathbf{F}) = \mathbf{L}$ , tedy  $Cov(X_i, F_j) = \ell_{ij}$   
kde  $\ell_{ij}$  jsou prvky matice  $\mathbf{L}$

# Předpoklady faktorové analýzy

- pokud platí výše uvedené vztahy, pak lze matici loadingů  $L$  určit jednoznačně až na přenásobení ortogonální maticí  $T$
- přenásobení se dá dále využít jako *rotace* k hledání nejlépe interpretovatelných faktorů
- nejčastěji používaná *rotace* je rotace **varimax** - ortogonální rotační matice  $T$
- výsledné loadingy jsou buď hodně velké nebo hodně malé, podle toho, jak sytí daný faktor

# Faktorová analýza

- hodnoty loadingů hledáme obdobně jako hlavní komponenty, tedy rozkladem korelační matice naměřených proměnných  $\mathbf{X}$
- faktorové skóry jsou odhadnuté hodnoty faktorů přiřazené jednotlivým pozorováním

$$\hat{\mathbf{f}}_j = (\hat{\mathbf{L}}(\hat{\sigma}^2 \mathbf{I})^{-1} \hat{\mathbf{L}}')^{-1} (\hat{\sigma}^2 \mathbf{I})^{-1} (\mathbf{x}_j - \bar{\mathbf{x}})$$

- faktorové skóry dále používáme jako nové "zjednodušující" proměnné

# Diskriminační analýza

**Příklad.** Uvažujme pacienty s různými nemocemi a mějme ke každému skupinu lékařských testů. Chceme pak najít způsob, jak určit, kterou nemocí pacient trpí jen na základě výsledků testů

- mějme mnohorozměrná data z několika různých populací
- chceme najít nejlepší možný způsob, jak na základě dat rozlišit populace mezi sebou
- výsledkem mají být pravděpodobnosti příslušnosti k jednotlivým skupinám

# Diskriminační analýza

## Nabízející se **postup**

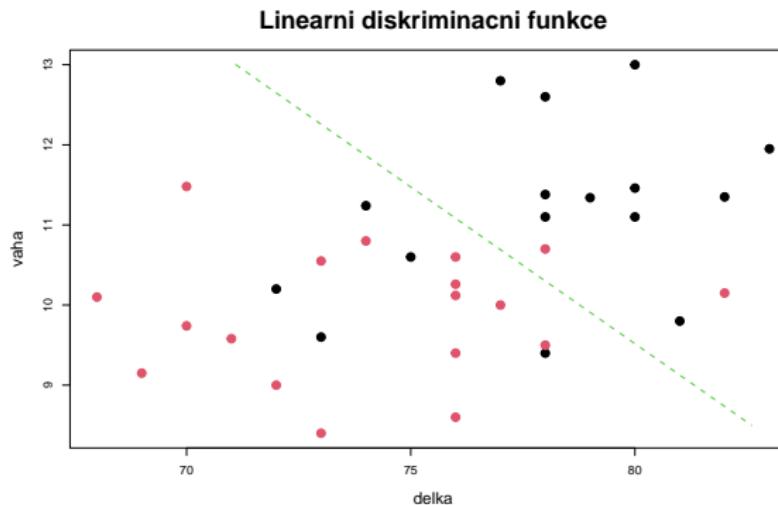
- pro každou populaci spočítáme průměrný vektor
- nového jedince zařadíme do populace, která bude mít svůj průměrný vektor nejblíže k jeho hodnotám

Výše uvedený "nabízející se" postup vede na **lineární diskriminační analýzu**.

- jak dobré je určené rozhodovací pravidlo zjistíme na základě klasifikace
- počet správně přiřazených jednotek a počet špatně přiřazených jednotek

# Lineární diskriminační analýza

Uvažujme dvě populace ve dvourozměrném případě. Lineádní diskriminační analýza je odděluje přímkou



# Diskriminační pravidlo pro dvě populace

Označme průměrné vektory v populacích  $\bar{\mathbf{X}}_{1,n}, \bar{\mathbf{X}}_{2,n}$ . Pro měření vzdáleností využijeme Mahalanobisovu vzdálenost  $d^2(\mathbf{X}, \mathbf{Y})$ . Rozhodovací pravidlo pak zní. Pokud

$$d^2(\mathbf{X}, \bar{\mathbf{X}}_{1,n}) < d^2(\mathbf{X}, \bar{\mathbf{X}}_{2,n}),$$

přiřadíme pozorování k první populaci, v opačném případě ke druhé.  
Aritmetickými operacemi lze získat vektor

$$\mathbf{b} = \mathbf{S}^{-1}(\bar{\mathbf{X}}_{1,n} - \bar{\mathbf{X}}_{2,n}),$$

kde  $\mathbf{S}$  je kombinovaná výběrová varianční matice obou populací

$$\mathbf{S} = \frac{n_1 - 1}{(n_1 - 1) + (n_2 - 1)} \mathbf{S}_1 + \frac{n_2 - 1}{(n_1 - 1) + (n_2 - 1)} \mathbf{S}_2$$

a  $n_1, n_2$  jsou velikosti výběrů z obou populací a  $\mathbf{S}_1, \mathbf{S}_2$  jsou výběrové varianční matice obou populací.

# Diskriminační pravidlo pro dvě populace

Rozhodovací pravidlo potom zní: pokud

$$\mathbf{b}^T \mathbf{X} - \mathbf{b}^T \frac{\bar{\mathbf{X}}_{1,n} + \bar{\mathbf{X}}_{2,n}}{2} > 0$$

pak pozorování patří do první populace, v opačném případě do druhé. Toto pravidlo je možné také přepsat v nevektorové podobě jako

$$\sum_{i=1}^k c_i X_i - c_0 > 0$$

kde koeficienty  $c_0, c_i$  lze jednoznačně odvodit z vektoru  $\mathbf{b}$ . Z tohoto zápisu je také zřejmé, že rozhodovací pravidlo je v tomto případě přímka.

**Poznámka:** Uvedené rozhodovací pravidlo je možné odvodit také metodou maximální věrohodnosti z hustoty mnohorozměrného normálního rozdělení

## Diskriminační pravidlo pro dvě populace

Vzniklou přímkou je možné dále "posouvat" přidáním dalších podmínek:

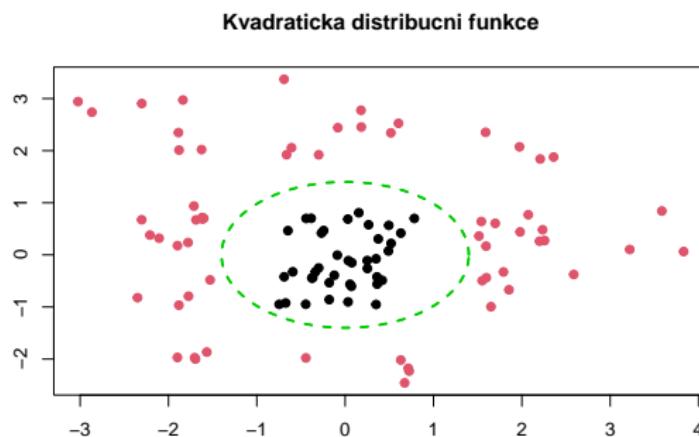
- podmínky na apriorní pravděpodobnosti obou populací, označme je  $\pi_1$  a  $\pi_2$   
využíváme, když je výskyt jedné populace výrazně častější než je tomu u populace druhé
- penalizace pro špatné zařazení jednotky, označme  $c(2|1)$  penalizaci za špatné přiřazení jednotky z první populace  
 $c(1|2)$  penalizaci za špatné přiřazení jednotky z druhé populace

Rozhodovací pravidlo se změní na

$$\mathbf{b}^T \mathbf{X} - \mathbf{b}^T \frac{\bar{\mathbf{X}}_{1,n} + \bar{\mathbf{X}}_{2,n}}{2} + \ln \left( \frac{c(2|1)}{c(1|2)} \frac{\pi_1}{\pi_2} \right) > 0$$

# Kvadratická diskriminační analýza

Někdy přímka pro oddělení populací nestačí a je potřeba použít křivku



# Diskriminační analýza

Diskriminační pravidlo pro dvě populace pak vypadá následovně. Pokud

$$\frac{1}{2} \mathbf{X}' (\mathbf{S}_1^{-1} - \mathbf{S}_2^{-1}) \mathbf{X} - (\bar{\mathbf{X}}_{1,n} \mathbf{S}_1^{-1} - \bar{\mathbf{X}}_{2,n} \mathbf{S}_2^{-1}) \mathbf{X} + k + \ln \left( \frac{c(1|2)}{c(2|1)} \frac{\pi_2}{\pi_1} \right) \leq 0$$

kde

$$k = \frac{1}{2} \ln \left( \frac{|\mathbf{S}_1|}{|\mathbf{S}_2|} \right) + \frac{1}{2} (\bar{\mathbf{X}}'_{1,n} \mathbf{S}_1^{-1} \bar{\mathbf{X}}_{1,n} - \bar{\mathbf{X}}'_{2,n} \mathbf{S}_2^{-1} \bar{\mathbf{X}}_{2,n})$$

pak nového jedince přiřadíme k první populaci, v opačném případě ke druhé

# Shluková analýza

## Hledání skupin v mnohorozměrných datech

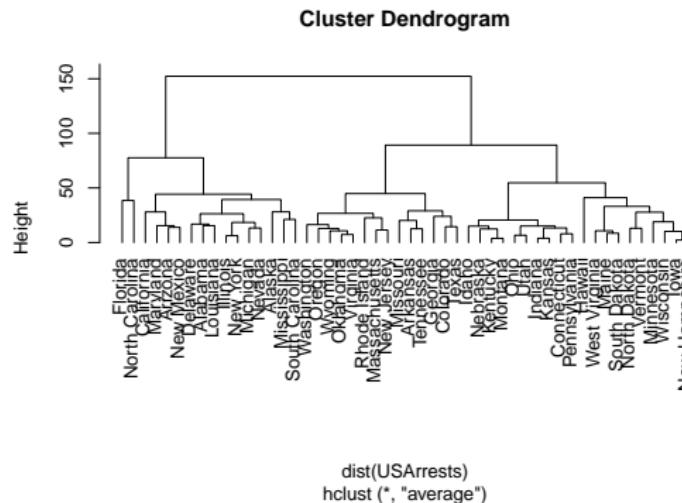
- chceme optimální počet skupin, tak aby
  - rozdíly mezi skupinami byly co možná největší
  - rozdíly v rámci skupin byly co možná nejmenší (homogenní skupiny)
- výsledné skupiny se snažíme popsat, aby se mezi nimi dalo rozlišovat
- základem analýz je měření vzdáleností mezi body

# Hierarchické shlukování

- začínáme s množinou bodů, kde každý tvoří jednu skupinu
- postupně slučujeme body do skupin, až tvoří jednu velkou skupinu
- podle způsobu měření vzdálenosti mezi skupinami rozlišujeme
  - **average linkage** – vzdálenost skupin je vzdálenost jejich středů (průměrů)
  - **single linkage** – vzdálenost skupin je vzdálenost nejbližších bodů
  - **complete linkage** – vzdálenost skupin je vzdálenost nejvzdálenějších bodů
  - **Wardova metoda** – skupiny jsou určené tak, aby se minimalizovala variabilita v rámci skupin
- Wardova metoda dává většinou "nejlepší výsledky"

# Hierarchické shlukování

Grafické znázornění hierarchického shlukování se nazývá **dendrogram**.



Opticky hledáme, kde ukončit shlukování, tj. kolik skupin je optimálních.

# K-means

## Postup shlukování metodou **K-means**

- nejprve se zvolí počet skupin  $p$
- náhodně vybereme  $p$  bodů v mnohorozměrném prostoru jako středy těchto skupin
- zařadíme prvek, který je nejbližší nějakému středu k této skupině
- středy se přepočítají
- poslední dva body se opakují, dokud nejsou rozřazeny všechny prvky

# Srovnání metod

## Nevýhody jednotlivých metod

- **hierarchické shlukování** – odlehlé hodnoty zde často tvoří samostatné skupiny
- **K-means** – pokud v datech nejsou jednoznačné skupiny, pak rozřazování dopadne jinak při jiné volbě náhodných středů

## Kanonické korelace

Máme dvě skupiny proměnných **X** a **Y** měřených na stejných jedincích a chceme zjistit, zda mezi těmito skupinami je nějaký vztah, případně jaký.

**Příklad.** Uvažujme dvě různé skupiny lékařských vyšetření a hodnotíme, zda obě tyto skupiny měří to samé, nebo ne.

Pro každou skupinu proměnných pak hledáme jejich vhodnou lineární kombinaci

$$U = \mathbf{a}^T \mathbf{X}, \quad V = \mathbf{b}^T \mathbf{Y}$$

takovou, že má mezi sebou maximální korelacii.

# Kanonické korelace

Označme

$$\begin{aligned} E(\mathbf{X}) &= \mu_1, & \text{Cov}(\mathbf{X}) &= \Sigma_{11} \\ E(\mathbf{Y}) &= \mu_2, & \text{Cov}(\mathbf{Y}) &= \Sigma_{22} \\ \text{Cov}(\mathbf{X}, \mathbf{Y}) &= \Sigma_{12} = \Sigma'_{21} \end{aligned}$$

Pak víme, že

$$\begin{aligned} \text{Var}(U) &= \mathbf{a}' \Sigma_{11} \mathbf{a} \\ \text{Var}(V) &= \mathbf{b}' \Sigma_{22} \mathbf{b} \\ \text{Cov}(U, V) &= \mathbf{a}' \Sigma_{12} \mathbf{b} \\ \text{Cor}(U, V) &= \frac{\mathbf{a}' \Sigma_{12} \mathbf{b}}{\sqrt{\mathbf{a}' \Sigma_{11} \mathbf{a}} \sqrt{\mathbf{b}' \Sigma_{22} \mathbf{b}}} \end{aligned}$$

## Kanonické korelace

Hledejme  $k$  dvojic proměnných  $U_i, V_i$ , kde  $k$  je počet proměnných v menší skupině. Pro tyto proměnné nechť platí

- proměnné  $U_1, V_1$  mají obě rozptyl roven jedné a maximalizují vzájemnou korelací
- proměnné  $U_2, V_2$  mají obě rozptyl roven jedné, jsou nekorelované s proměnnými  $U_1, V_1$  a maximalizují vzájemnou korelací
- ...
- proměnné  $U_k, V_k$  mají obě rozptyl roven jedné, jsou nekorelované s proměnnými  $U_1, \dots, U_{k-1}, V_1, \dots, V_{k-1}$  a maximalizují vzájemnou korelací.

Takovéto páry proměnných  $U_i, V_i$  se nazývají kanonické proměnné a jejich vzájemné korelace potom **kanonické korelace**.

Platí

$$\text{Cor}(U_1, V_1) \geq \text{Cor}(U_2, V_2) \geq \dots \geq \text{Cor}(U_k, V_k)$$

# Kanonické korelace

Matematická konstrukce kanonických proměnných. Lineární koeficienty **a** a **b** lze určit jako

- $\mathbf{a} = \mathbf{e} \mathbf{S}_{11}^{-1/2}$ , kde **e** jsou vlastní vektory matice  $\mathbf{S}_{11}^{-1/2} \mathbf{S}_{12} \mathbf{S}_{22}^{-1} \mathbf{S}_{21} \mathbf{S}_{11}^{-1/2}$
- $\mathbf{b} = \mathbf{f} \mathbf{S}_{22}^{-1/2}$ , kde **f** jsou vlastní vektory matice  $\mathbf{S}_{22}^{-1/2} \mathbf{S}_{21} \mathbf{S}_{11}^{-1} \mathbf{S}_{12} \mathbf{S}_{22}^{-1/2}$
- matice **S** jsou odhady matic  $\Sigma$ .

# Kanonické korelace

Pokud jsou skupiny proměnných  $\mathbf{X}$  a  $\mathbf{Y}$  nezávislé, pak jejich teoretické kovarianční matice  $\Sigma_{12}$  a  $\Sigma_{21}$  jsou nulové. Jak však pomocí kanonických korelací tuto nezávislost otestovat?

Můžeme testovat několik různých hypotéz

- $H_0$  : všechny kanonické korelace jsou nulové, tedy  $\Sigma_{12} = 0$
- $H_0$  : druhá a další kanonické korelace jsou nulové a první je nenulová, tedy  $\rho_2 = \dots = \rho_k = 0$
- $H_0$  : třetí a další kanonické korelace jsou nulové a první dvě jsou nenulové, tedy  $\rho_3 = \dots = \rho_k = 0$
- atd.

kde  $\rho_i$  je  $i$ -tá kanonická korelace.

# Kanonické korelace

Testová statistika první nulové hypotézy má tvar

$$n \ln \left( \frac{|\mathbf{S}_{11}||\mathbf{S}_{22}|}{|\mathbf{S}|} \right) = -n \ln \prod_{i=1}^k (1 - \hat{\rho}_i^2)$$

kde  $\mathbf{S}$  je matice složená z  $\mathbf{S}_{11}, \mathbf{S}_{12}, \mathbf{S}_{21}, \mathbf{S}_{22}$ . Tato statistika má za platnosti  $H_0$  asymptoticky  $\chi^2$  rozdělení o  $kp$  stupních volnosti, kde  $p$  je počet proměnných ve větší skupině.

Testová statistika dalších testů má tvar

$$-(n - 1 - \frac{1}{2}(k + p + 1)) \ln \prod_{i=m+1}^k (1 - \hat{\rho}_i^2)$$

a za platnosti  $H_0$  má asymptoticky  $\chi^2$  rozdělení o  $(k - m)(p - m)$  stupních volnosti.  $m$  je zde počet kanonických korelací, které nechceme testovat.

# Metoda maximální věrohodnosti

Způsob **odhadu parametru** určitého rozdělení.

- označme odhadovaný parmetr  $\hat{\theta}$
- mějme naměřené hodnoty  $X_1, X_2 \dots, X_n$  z rozdělení s hustotou  $f(x, \theta)$
- chceme takové  $\hat{\theta}$ , aby pravděpodobnost, že hodnoty  $X_i$  pochází z rozdělení  $f(x, \hat{\theta})$ , byla maximální
- potřebujeme konkrétní specifikaci pravděpodobnostního rozdělení  $f(x, \theta)$

## Metoda maximální věrohodnosti

Naměřené hodnoty  $X_1, \dots, X_n$  jsou nezávislé. Jejich sdružená hustota je tedy rovna

$$f(x_1, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta)$$

větší hodnota této funkce vyjadřuje větší shodu pozorovaných hodnot s předpokládaným rozdělením.

Odhad parametru  $\theta$  získáme maximalizací této funkce přes  $\theta$

$$\hat{\theta} = \arg \max_{\theta \in \Theta} f(x_1, \dots, x_n | \theta)$$

kde  $\Theta$  je prostor všech možných hodnot parametru.

# Metoda maximální věrohodnosti

Uvažujeme-li tuto funkci jako funkci parametru  $\theta$ , nazýváme ji **věrohodnostní funkce** a  $\hat{\theta}$  **maximálně věrohodným odhadem**.

Častěji se pracuje s logaritmickou věrohodnostní funkcí

$$\ell(\theta|x_1, \dots, x_n) = \ln L(\theta|x_1, \dots, x_n) = \ln \prod_{i=1}^n f(x_i|\theta) = \sum_{i=1}^n \ln f(x_i|\theta)$$

Tuto funkci pad derivujeme podle  $\theta$  a položíme rovnu nule.

Metoda používaná pro odhad parametrů v zobecněné lineární a nelineární regresi.

# Metoda maximální věrohodnosti

**Příklad.** Hledejme maximálně věrohodný odhad parametru  $\lambda$  z poissonova rozdělení, které má hustotu  $f(x|\lambda) = \frac{e^{-\lambda}\lambda^{x_i}}{x_i!}$ .  
 Logaritmus věrohodnostní funkce pak má tvar

$$\begin{aligned}\ell(\theta|x_1, \dots, x_n) &= \ln \prod_{i=1}^n \frac{e^{-\lambda}\lambda^{x_i}}{x_i!} = \ln \frac{e^{-\lambda}\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} \\ &= \sum_{i=1}^n x_i \ln \lambda - n\lambda - \ln(\prod_{i=1}^n x_i!)\end{aligned}$$

derivací podle  $\lambda$  dostanu

$$\frac{d\ell}{d\lambda} = \frac{\sum_{i=1}^n x_i}{\lambda} - n$$

a tedy  $\hat{\lambda} = \frac{\sum_{i=1}^n x_i}{n}$

# Dodatky k regresním modelům

Uvažujme model lineární regrese

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + e_i$$

kde

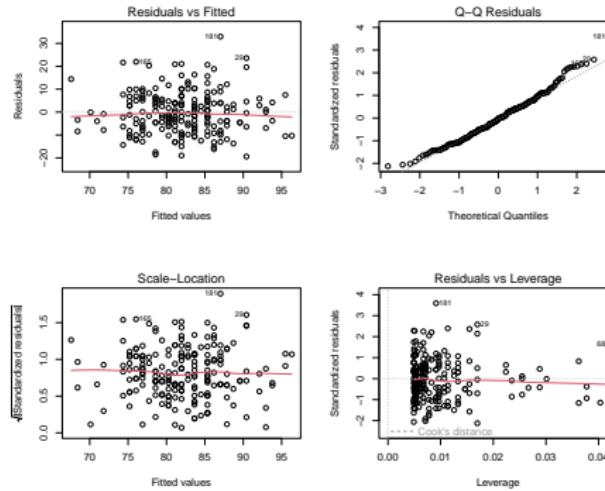
- $Y_i$  jsou hodnoty závisle proměnné
- $X_{1i}, \dots, X_{ki}$  jsou hodnoty nezávisle proměnných  $X_1, \dots, X_k$
- $\beta_0, \dots, \beta_k$  jsou regresní koeficienty
- $e_i$  jsou náhodné chyby

## Předpoklady modelu lineární regrese

- $e_i \sim iid N(0, \sigma^2)$  jsou nezávislé, stejně rozdělené náhodné veličiny s normálním rozdělením, nulovou střední hodnotou a konstantním rozptylem
- $X_1, \dots, X_k$  jsou vzájemně nezávislé proměnné
- mezi závisle proměnnou  $Y$  a nezávisle proměnnými  $X$  je lineární vztah
- v datech nejsou vlivná pozorování

# Testy předpokladů

V R-ku máme k dispozici diagnostické grafy



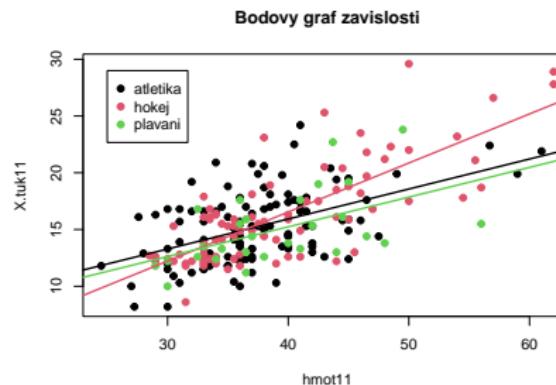
Dále test normality, test homoskedasticity, test nekorelovanosti residuí, test multikolinearity, Cookovu vzdálenost.

# Závislost na kategorické proměnné

- do modelu lze vkládat i kategorické regresory
- závislost na nich se modeluje pomocí **dummy variables**
  - $Z_1 = 1 \dots$  když nastane 1. kategorie a  $Z_1 = 0 \dots$  jinak
  - $Z_2 = 1 \dots$  když nastane 2. kategorie a  $Z_1 = 0 \dots$  jinak
  - :
  - $Z_{k-1} = 1 \dots$  když nastane (k-1). kategorie a  $Z_1 = 0 \dots$  jinak  
kde  $k$  je počet kategorií
  - proč chybí  $k$ -tá proměnná?
- v modelu se testuje, jak se která kategorie liší od referenční

# Interakce

Jak se nezávisle proměnné ovlivňují při současném vlivu na proměnnou závislou



- závislost procenta tuku na hmotnosti je stejná u atletiky a plavání – není interakce
- závislost procenta tuku na hmotnosti se u hokejistů liší od ostatních sportů – interakce

# Kroková regrese

Hledáme optimální regresní model

- **backward** – udělá se co nejsložitější model a postupně se z něj ubírají nevýznamné proměnné  
vždy se ubere proměnná s nejmenším vlivem (nejvyšší p-hodnotou, která optimalizuje AIC)  
končím, když mám v modelu jen významné proměnné
- **forward** – do modelu bez nezávislých proměnných se postupně po jedné přidávají  
vždy se přidá proměnná s největším vlivem (nejnižší p-hodnotou, která optimalizuje AIC)  
končím, když nemohu přidat žádnou významnou proměnnou
- **both sided** – kombinuje obě výše zmíněné  
v každém kroku zkusím jednu proměnnou přidat, ale také ubrat (optimalizace AIC)

# Intervaly spolehlivosti

- pro regresní koeficienty

$$b_j \pm s.e.(b_j) t_{n-k-1}(1 - \alpha/2)$$

- pro odhad

$$b_0 + b_1 x_0 \pm s d(x_0) t_{n-k-1}(1 - \alpha/2)$$

- pro předpověď

$$b_0 + b_1 x_0 \pm s \sqrt{1 + d^2(x_0)} t_{n-k-1}(1 - \alpha/2)$$

- kde  $s$  je střední chyba residiuí a

$$d^2(x_0) = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

# Interpretace regresních koeficientů

## Mnohonásobná lineární regrese

Mějme odhadnutý regresní model

$$\text{průtok vody v řece} = 53 + 2.6 \times \text{srážky} + 3.8 \times \text{pole} + 5.9 \times \text{město}$$

- na jeden díl srážek stoupne průtok vody v průměru o 2.6 na stejném typu půdy
- v polích stoupne průtok vody o 3.8 více než v lese při stejném množství srážek

## Logistická regrese

Mějme odhadnutý regresní model

$$\text{logit(přežití)} = -0.07 - 1.34 \times 2.\text{třída} - 2.19 \times 3.\text{třída} - 1 \times \text{posádka} + 3.2 \times \text{ženy}$$

- cestující ve 3. třídě mají  $1 / \exp\{-2.19\} = 8.9$ , tj. téměř 9 krát menší šanci na přežití, než cestující v první třídě, při stejném pohlaví
- ženy mají  $\exp\{3.2\} = 24.2$  krát větší šanci na přežití než muži cestující ve stejné třídě

# Zobecněné lineární modely

- 0 – 1 závislá proměnná – **Logistická regrese**
- ordinální závislá proměnná – **Ordinální regrese**
- závislá proměnná počet (count data) – **Poissonova regrese**

# Ordinální regrese

- kombinace několika logistických regresí
- závislá proměnná v těchto jednotlivých modelech je

$$\begin{aligned} Y &= 0 \dots X \leq j \\ &= 1 \dots X > j \end{aligned}$$

- modeluje se šance přechodu do vyšší kategorie
- předpokladem je, že všechny dílčí logistické regrese mají stejný "směr", tedy lineární člen
- absolutní člen je pro každou logistickou regresi individuální

# Poissonova regrese

- závisle proměnná je **počet**
- pomocí této regrese je možné modelovat i vztahy v kontingenční tabulce
- model má tvar

$$\log(Y_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + e_i$$

- předpokladem je, že rozptyl závisle proměnné je stejný jako její střední hodnota (vlastnost Poissonova rozdělení)
- není-li splněno
  - použijte se *dispersion parameter* ⇒ **Quasi-Poisson**
  - použije se namísto poissonova rozdělení **negativně binomické rozdělení**

# Typy testů

Statistické testy dělíme na

- **Parametrické**

předpokládají určité rozdělení dat, nejčastěji normální

- **Neparametrické**

jsou použitelné nezávisle na rozdělení dat

- Založené na **pořadích**

namísto původních hodnot pracují s jejich pořadími,  
nenáročné na výpočet

- Založené na **přeuspořádání** (resampling)

pracují přímo s naměřenými hodnotami, které různě  
přeskupují

- Permutační
    - Bootstrap

# Permutační testy

- počítá se testová statistika
- **princip:** jak si stojí aktuálně naměřená hodnota testové statistiky mezi statistikami, které je možné získat permutací původních hodnot
- **p-hodnota:** je podíl testových statistik v absolutní hodnotě větších než aktuální naměřená hodnota

# Permutační testy

## Příklad pro dvouvýběrový test

- porovnáváme dva nezávislé výběry s počty pozorování  $n_1$  a  $n_2$
- testujeme
  - $H_0$  : střední hodnoty jsou stejné
  - $H_1$  : střední hodnoty se liší
- vypočteme testovou statistiku klasického dvouvýběrového t-testu

$$T = \frac{\bar{X} - \bar{Y}}{S} \sqrt{\frac{n_1 n_2}{n_1 + n_2}}$$

kde

$$S = \frac{1}{n_1 + n_2 - 2} \left( \sum_{i=1}^{n_1} (X_i - \bar{X})^2 + \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2 \right)$$

# Permutační testy

## Příklad pro dvouvýběrový test

- spočítáme velké množství (alespoň  $N = 10000$ ) permutací původních hodnot při neměnných rozsazích výběrů  $n_1, n_2$
- pro každou permutaci spočítáme hodnotu testové statistiky  $T_i$
- vypočteme p-hodnotu

$$p = \frac{\# T_i : |T_i| \geq T}{N}$$

# Permutační testy

## Vlastnosti permutačních testů

- permutační test lze využít pro libovolnou testovou statistiku
- lze ho využít bez předpokladu na rozdělení dat
- předpokladem je přibližně stejný rozptyl ve výběrech
- je-li příliš malý počet pozorování, je malý i počet různých permutací a tedy i počet možných různých p-hodnot
- pro menší vzorky je možné spočítat "*přesnou*" p-hodnotu
- udržují hladinu významnosti, mnohdy lépe než klasické testy
- výpočetně náročné

# Bootstrap

- princip je obdobný jako u permutačních testů
- počítá se testová statistika a její aktuální hodnota se porovnává s hodnotami získanými z náhodných výběrů z dat
- náhodné výběry se ale nezískávají permutováním, ale **náhodným výběrem s vracením**
- bootstrapové náhodné výběry mohou některé původní hodnoty obsahovat víckrát a jiné vůbec
- častěji se používá pro výpočet **intervalů spolehlivosti**, ale je možné je využít i k testování
- optimální, pokud chceme odhadnout **rozdělení** měřeného parametru

# Odhady metodou Jackknife

Jednoduché přeuspořádání původních hodnot používané k odhadům libovolných parametrů

- mějme jeden výběr a potřebujeme odhadnout parametr  $\theta$  (průměr, rozptyl, medián, šíkmost, ...)
- tvoříme náhodné výběry, pro něž vypočteme odhadovaný parametr a výsledky pak zprůměrujeme
- náhodné výběry metodou *Jackknife* vznikají vynecháním jedné hodnoty z původních dat
- pro  $n$  pozorování vytvořím  $n$  přeuspořádaných výběrů o  $n - 1$  hodnotách

# Odhady metodou Jackknife

## Vlastnosti metody *Jackknife*

- výpočetní jednoduchost
- deterministická, tj. nenáhodná metody (vždy dostanu stejný výsledek)
- optimálně pracuje při známém rozdělení dat
- snižuje vychýlení (bias) odhadu
- nedoporučuje se používat při velké variabilitě v datech nebo při příliš komplexních modelech

# Bayesovská statistika

- předpokládejme náhodnou veličinu  $X$  s hustotou rozdělení  $f(x|\theta)$  závislou na parametru  $\theta$
- mějme náhodný výběr  $x = (x_1, x_2, \dots, x_n)$  z rozdělení  $X$
- v klasické (frekvenční) statistice předpokládáme, že  $\theta$  je konstanta, kterou chceme odhadnout na základě výběru  $x$
- Bayesovská statistika předpokládá, že  $\theta$  je náhodná veličina s rozdělením/hustotou  $g(\cdot)$
- cílem je odhadnout parametry rozdělení  $g$

# Bayesovská statistika

- k dispozici máme *apriorní rozdělení*  $\pi(\theta)$  – náš předpoklad, jak by se měla náhodná veličina chovat
- a dále náhodný výběr  $x$
- cílem je získat *aposteriorní rozdělení*  $\pi(\theta|x)$
- pomocí Bayesovy věty lze odvodit, že

$$\pi(\theta|x) \approx f(x|\theta)\pi(\theta)$$

- nemáme-li žádnou představu o apriorním rozdělení, používá se *neurčité apriorní rozdělení*, tj. rozdělení konstantní
- odhad aposteriorního rozdělení se realizuje pomocí Markov Chain Monte Carlo (MCMC) metod